
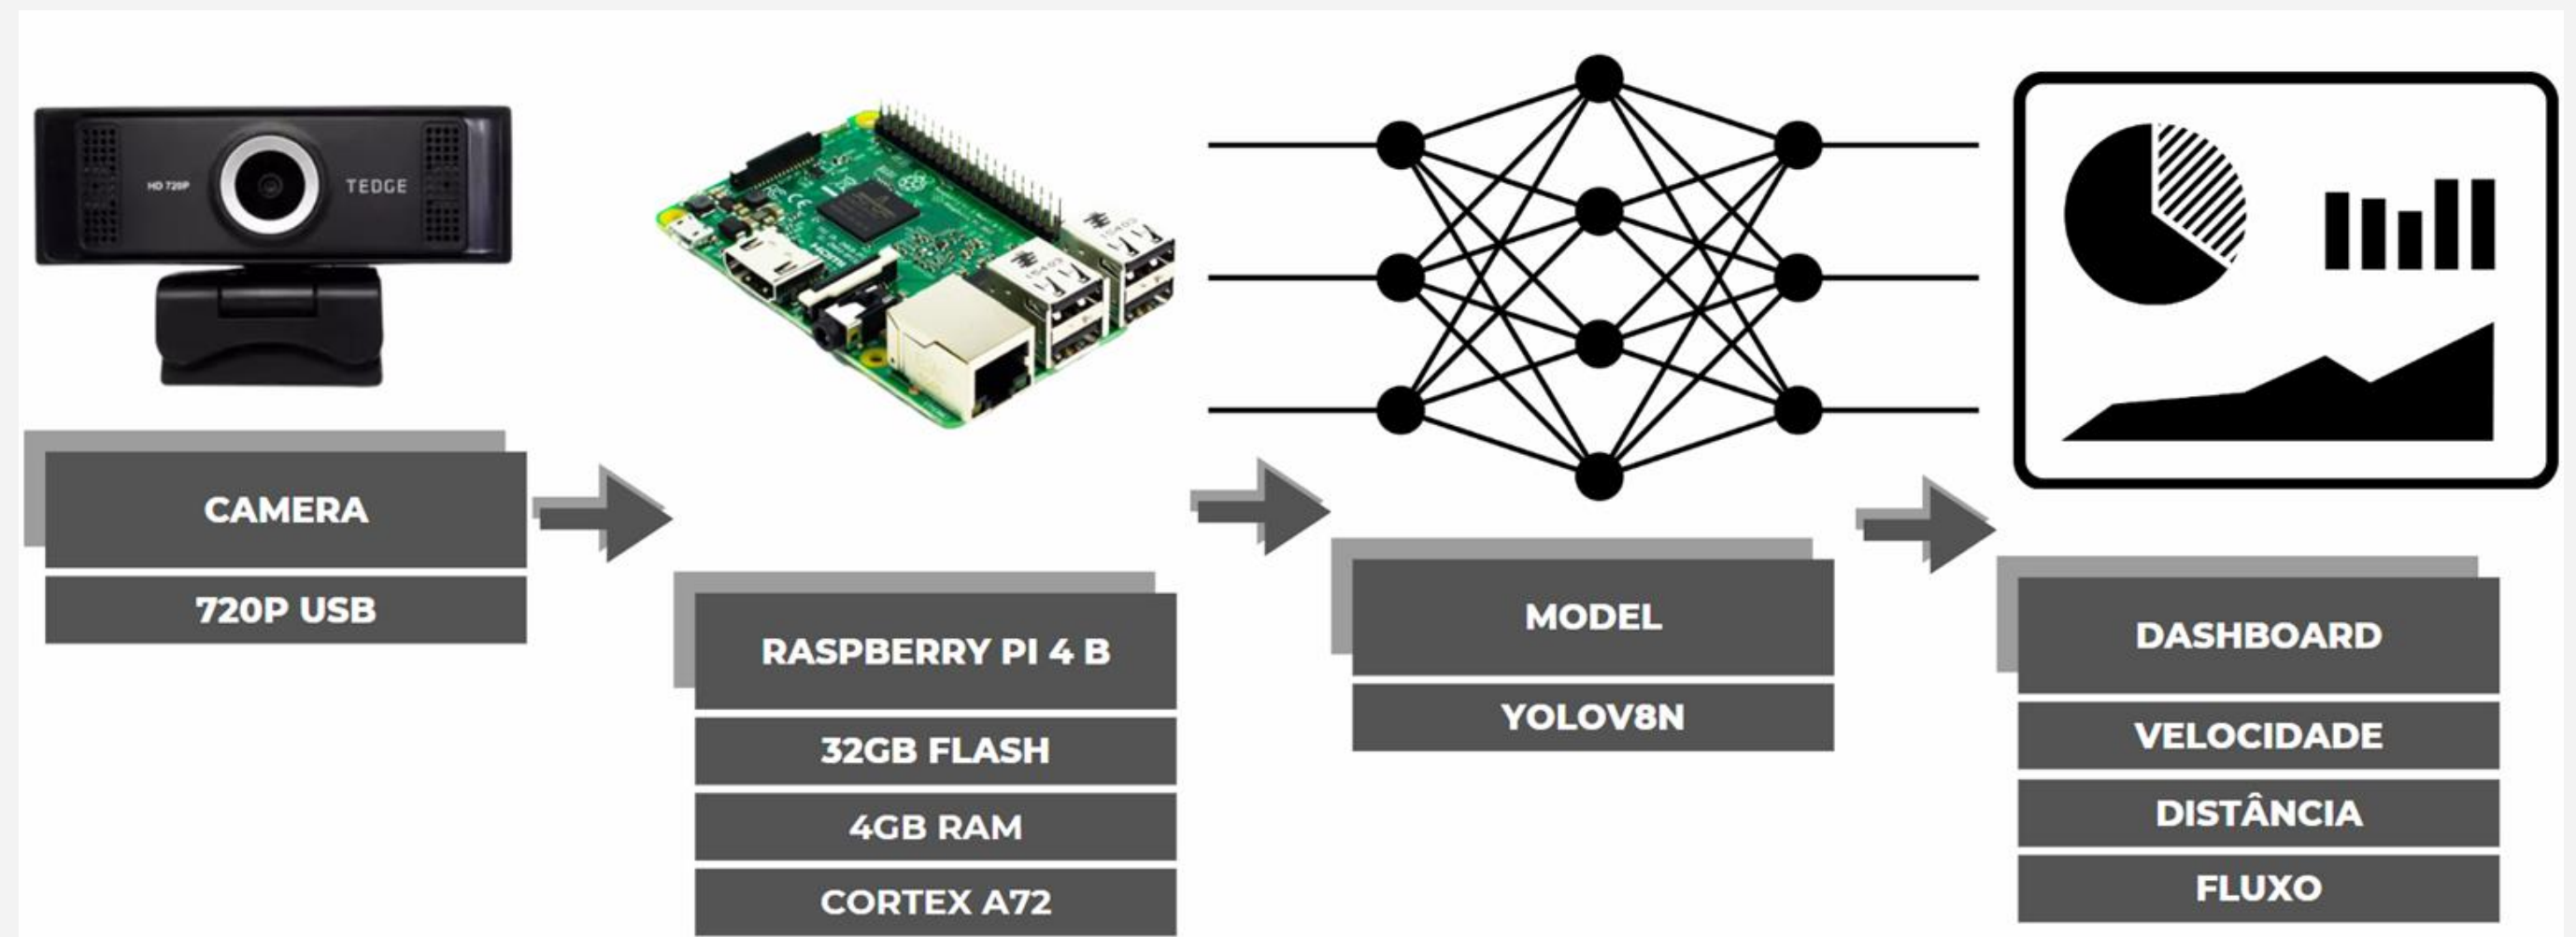


EdgeML aplicado ao Rastreamento de veículos e controle de tráfego

Hyago Vieira Leme Barbosa Silva
hyago.silva@mtel.inatel.br



Dispositivos e arquitetura da solução





Objetivos do projeto




Contexto:




A necessidade de sistemas com controle e análise de dados eficientes de rastreamento de veículos para logística, segurança e gestão de forma automática, no tráfego e mobilidade brasileira.

Problema:

Latência, largura de banda e custos de transmissão de dados envolvendo altos custos. Mobilidade, no Brasil, é um grande problema, colisões, velocidades, ultrapassagens enfim. Demanda de espaço e vagas em eventos. Controle de tempo de carros. Análise de segurança sobre carros, sendo eles roubados, ou acidentes que possam acontecer. E principalmente o risco à vida.






Projeto e Solução


A proposta utiliza **rastreamento de veículos**, proporcionando análise de algumas **métricas**, através de um sistema com **dashboard**, uma solução mais eficiente e **econômica**.


- Redução de Custos;
- Controle de Velocidade e Distância;
- Análise de Fluxo de Tráfego;
- Identificação e notificação de infração;
- Segurança.



Desafios atuais para EdgeML e visão computacional

- Sistema com maior velocidade de **processamento**, **recursos escassos**, **memória** e **energia**, frisando o bem ao meio ambiente, buscando ainda uma boa precisão.
- Modelos complexos, redução de custos e desenvolvedores de soluções são escassos.
- Segurança no trânsito, com problemas devido à falha humana, tecnologias complexas, custosas e antigas


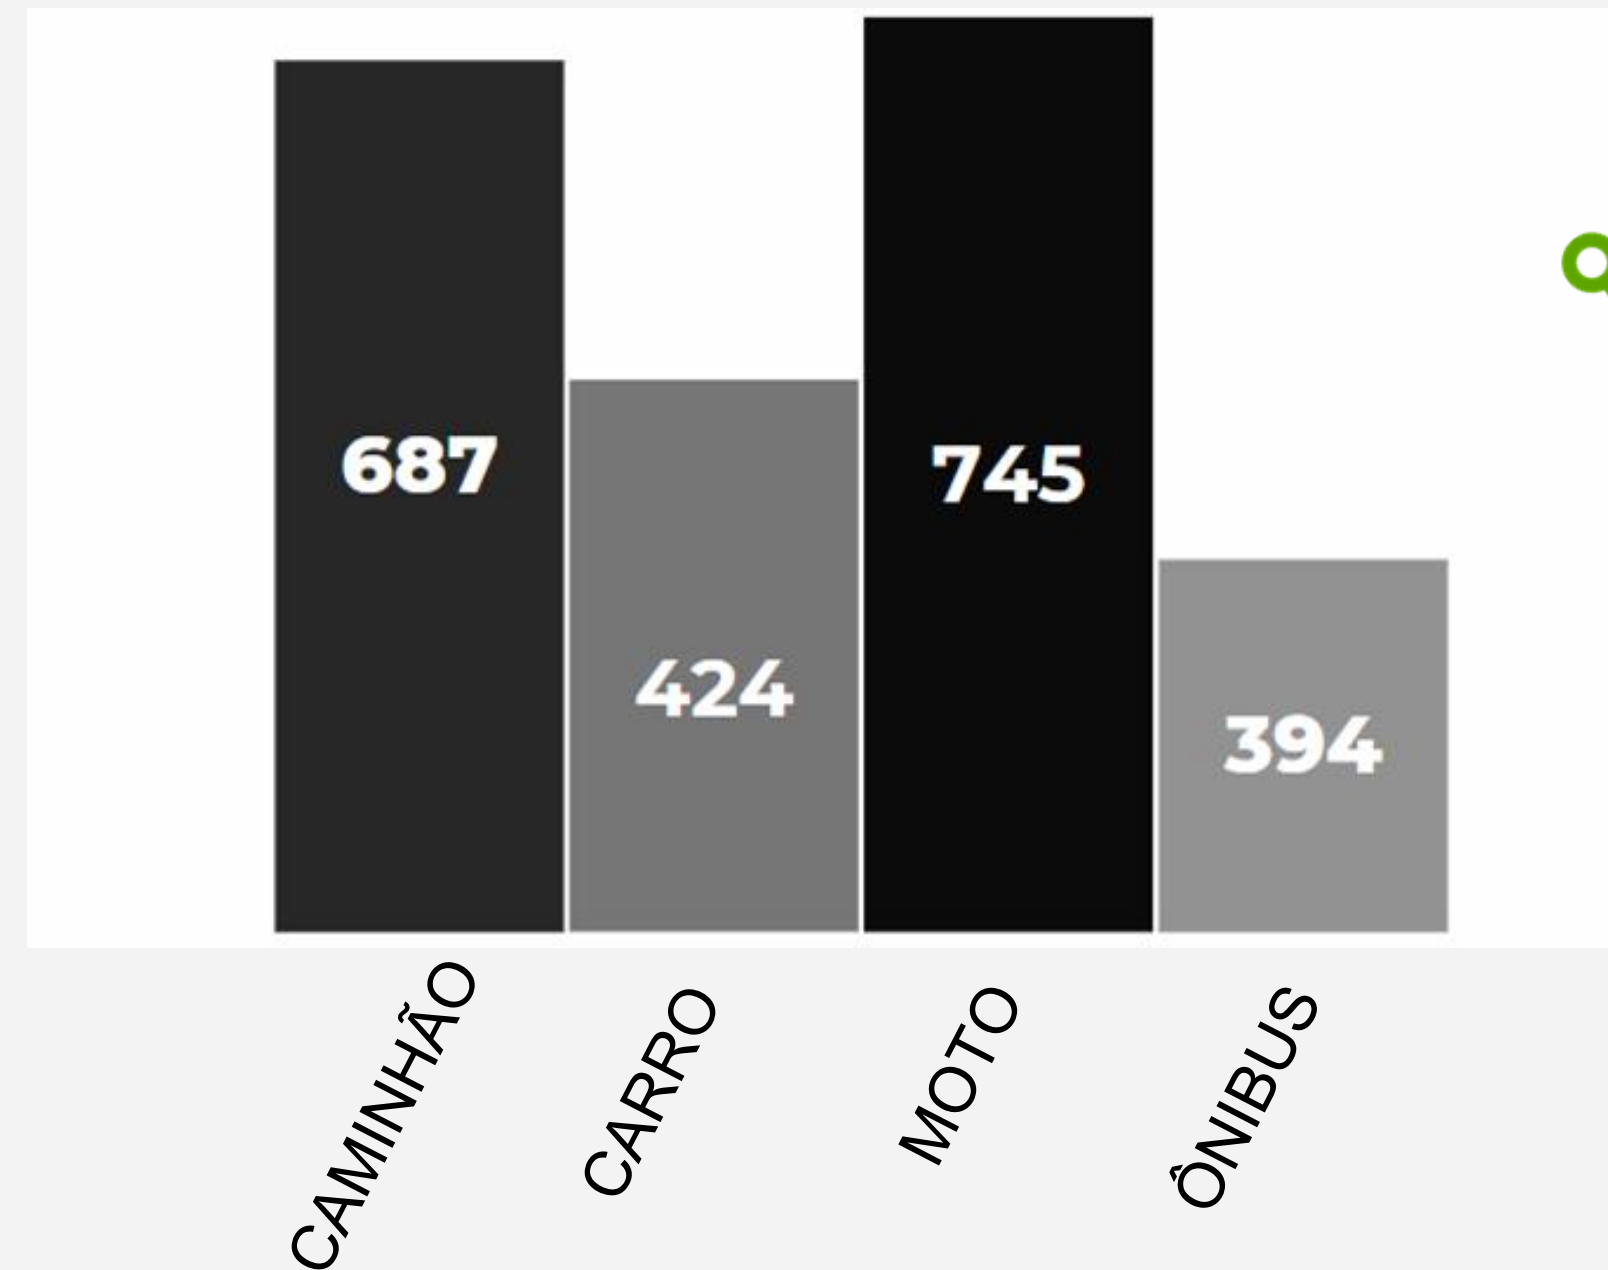






Base de dados utilizada

Roboflow [1]


- Divisão 70% Treino, 20% validação e 10% teste





Mapeamento da área de interesse



1920x1080 PX



Mapeamento da área de interesse



Algorithm 1 Transformação de Pixel para Metro

Class ViewTransformer

function VIEWTRANSFORMER(source, target)

 self.math \leftarrow CV2.FINDHOMOGRAPHY(source, target)

end function

function TRANSFORMPOINTSPIXELTOMETER(pointsPixel)

if pointsPixel == 0 ou self.math == None **then**


return pointsPixel


end if

 pointsMeter \leftarrow CV2.PERSPECTIVETRANSFORM(pointsPixel, self.math)


return pointsMeter

end function





Mapeamento da área de interesse





$$H = \begin{bmatrix} h_{00} & h_{01} & h_{02} \\ h_{10} & h_{11} & h_{12} \\ h_{20} & h_{21} & h_{22} \end{bmatrix}$$

Considerando o primeiro conjunto de pontos (x_1, y_1) na primeira imagem e (x_2, y_2) na segunda imagem. Então, a Homografia H mapeia-os da seguinte maneira.




$$\begin{bmatrix} x_1 \\ y_1 \\ 1 \end{bmatrix} = H \begin{bmatrix} x_2 \\ y_2 \\ 1 \end{bmatrix} = \begin{bmatrix} h_{00} & h_{01} & h_{02} \\ h_{10} & h_{11} & h_{12} \\ h_{20} & h_{21} & h_{22} \end{bmatrix} \begin{bmatrix} x_2 \\ y_2 \\ 1 \end{bmatrix}$$





Mapeamento da área de interesse

Exemplo



Cálculo da Velocidade


1. Ao obter a matriz de transformação, de píxeis para metros, a cada **frame**, ou **instante desejado**, é obtido a **coordenada atual** no veículo e a mesma é armazenada em uma lista que possui: coordenadas em um **espaço de tempo** e o respectivo **identificador** do objeto.

2. Calcula-se a **distância percorrida** pelo objeto como a **diferença**, em **módulo**, entre a coordenada atual e anterior.

3. Determina-se o **tempo decorrido** durante o movimento do objeto, utilizando o número de **quadros armazenados** na lista de coordenadas e a **taxa de quadros por segundo** do vídeo ou webcam.

4. Calcula-se a **velocidade** do objeto utilizando a **fórmula da velocidade média** e já convertido para quilômetros por hora, multiplicando por 3,6.

$$\text{Velocidade} = \frac{\text{distância}}{\text{tempo}}$$



Cálculo da Velocidade


4. Caso a velocidade ultrapasse 30km/h, é retirado uma foto, e enviada por email utilizando o APP key do Gmail, com protocolo SMTP. Informando no e-mail, a imagem com o ID, velocidade e as distâncias entre outros objetos, se existirem.

5. Aplica-se a média móvel exponencial (MME) para suavizar a série temporal das velocidades. A fórmula da MME é dada por:

$$MME_t = \alpha \cdot Vm_t + (1 - \alpha) \cdot MME_{t-1}$$

Obs.: Onde α (alfa), é o fator de suavização. Quanto maior o valor de alfa, a velocidade é mais atrelada ao presente, quanto menor o valor de alfa, estaria mais corresponde ao passado.

6. Por fim, é adicionado a velocidade suavizada ao *bounding boxes* do objeto.



Cálculo da Velocidade


```
function CALCULATE_SPEED(labels, detections, coordinates,
fps)
  for each id in detections.id do
    if id  $\notin$  coordinates then
      labels.append(f'#{id}')
    else
      coordinate_anterior  $\leftarrow$  coordinates[id][-1]
      coordinate_atual  $\leftarrow$  coordinates[id][0]
      distance  $\leftarrow$  abs(coordinate_anterior - coordinate_atual)
      time  $\leftarrow$  len(coordinates[id]) / video_fps
      speed  $\leftarrow$  distance / time  $\cdot$  3.6
      if previous_ema is None then
        previous_ema  $\leftarrow$  speed
      else
        ema_speed  $\leftarrow$  CALCULATE_EMA(previous_ema,
speed, ALPHA)
      if ema_speed > 30 then
        SEND_EMAIL(frame, ema_speed, mensagem)
      end if
      labels.append(f'#{id} {int(ema_speed) km/h}')
    end if
  end for
end function
```

Algorithm 2 Calcular Velocidade

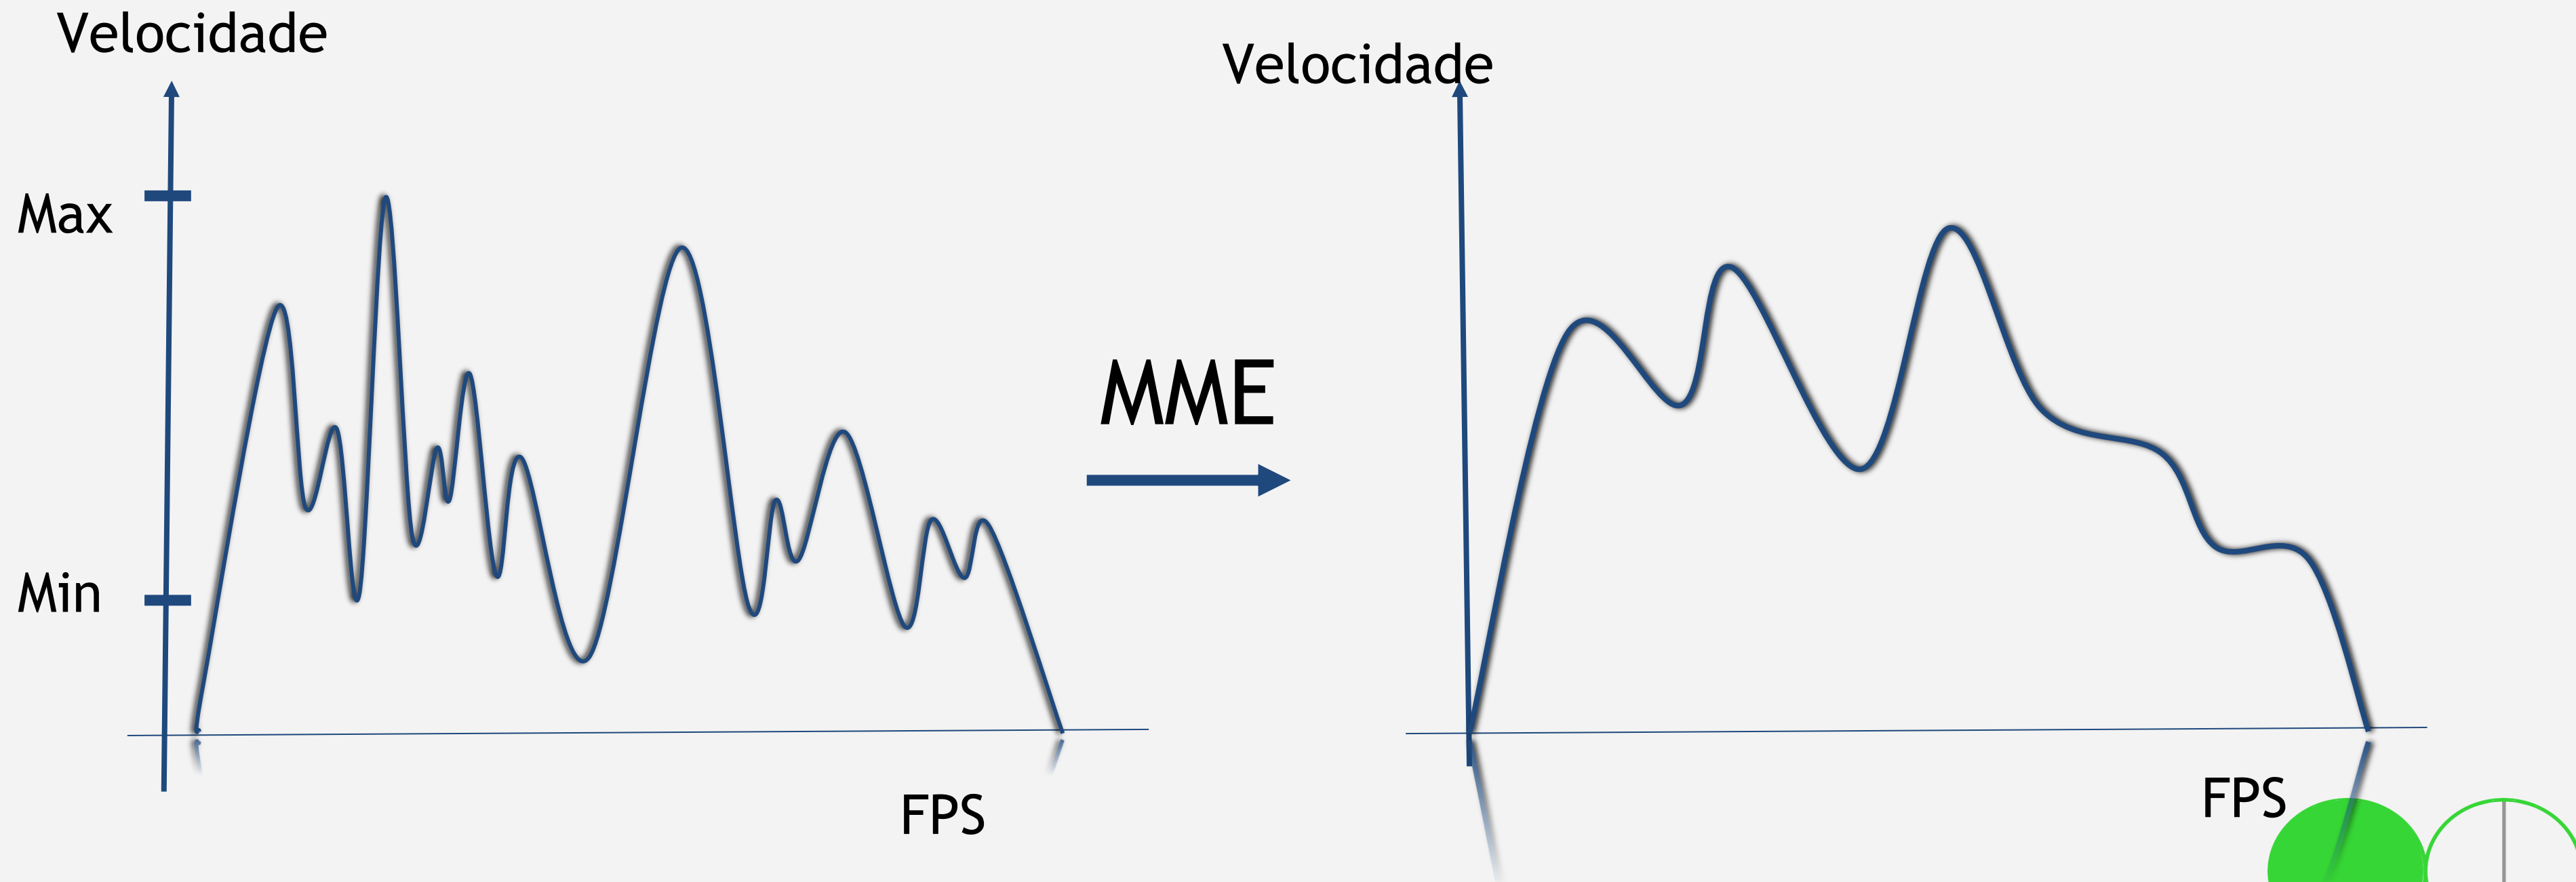
const ALPHA = 0.5

```
function CALCULATE_EMA(previousEMA, currentSpeed)
  return ALPHA  $\cdot$  currentSpeed + (1 - ALPHA)  $\cdot$  previ-
ousEMA
end function
```






Cálculo da Velocidade



$$0 < \alpha < 1$$

$$MME_t = \alpha \cdot Vm_t + (1 - \alpha) \cdot MME_{t-1}$$



Cálculo da Distância

Algorithm 3 Cálculo da distância entre veículos

function EUCLIDEAN_DIST(pointA, pointB)

return $\sqrt{(pointA_x - pointB_x)^2 + (pointA_y - pointB_y)^2}$

end function

function DRAW_LINE(frame, pointA, pointB, distance)


 CV2.LINE(pointA, pointB)

 text_position $\leftarrow ((pointA_x + pointB_x) // 2, (pointA_y + pointB_y) // 2)$

 CV2.PUTEXT(frame, distance, text_position)

return frame

end function





Código principal

```
for each frame in video_info.total_frames do
    result ← MODEL(frame)[0]
    detec ← SV.DETECTIONS.FROM_ULTRALYTICS(result)
    detec ← polygon_zone.trigger(detec)
    detec ← DETEC.WITH_NMS(IOU_THRESHOLD)
    detec ← BYTE_TRACK.UPDATE_WITH_DETECTIONS(detec)
    pts ← DETEC.GET_ANCHORS_COORDINATES(BC)
    pts_mt ← VIEW.TRANSFORMPXToMT(pts)
    for each id, [_, y] in ZIP(detec.tracker_id, pts_mt) do
        coords[id].append(y)
    end for
    labels ← []
    CALCULATESPEED(labels, detec, coords, video_info.fps)
    for each i in range(len(pts_mt) - 1) do
        for each j in range(i + 1, len(pts_mt)) do
            ptA ← tuple(pts[i])
            ptB ← tuple(pts[j])
            distance ← EUCLIDEAN_DIST(pts_mt[i], pts_mt[j])
            annotated_frame ← DRAW_LINE(frame, ptA, ptB,
distance)
        end for
        Anota o frame no video alvo
    end for
```

Algorithm 4 Código principal


Require: algoritmos 1, 2 e 3

```
view ← ViewTransformer(SOURCE,TARGET)
model ← YOLO(MODEL_NAME)
previous_ema ← None
video_info ← SV.VIDEOINFO.FROM_VIDEO_PATH(VIDEO_PATH)
frame_gen ← SV.GET_VIDEO_FRAMES_GENERATOR(VIDEO_PATH)
tracker ← SV.BYTETRACK(frame_rate=video_info.fps,
track_activation_threshold=CONFIDENCE_THRESHOLD)
polygon_zone ← SV.POLYGONZONE(polygon=SOURCE)
coords ← DEFAULTDICT(lambda:deque(maxlen=video_info.fps))
```




Resultados



- 0 – Caminhão;
- 1 – Carro;
- 2 – Moto;
- 3 – Ônibus e;
- 4 –Background (Fundo).



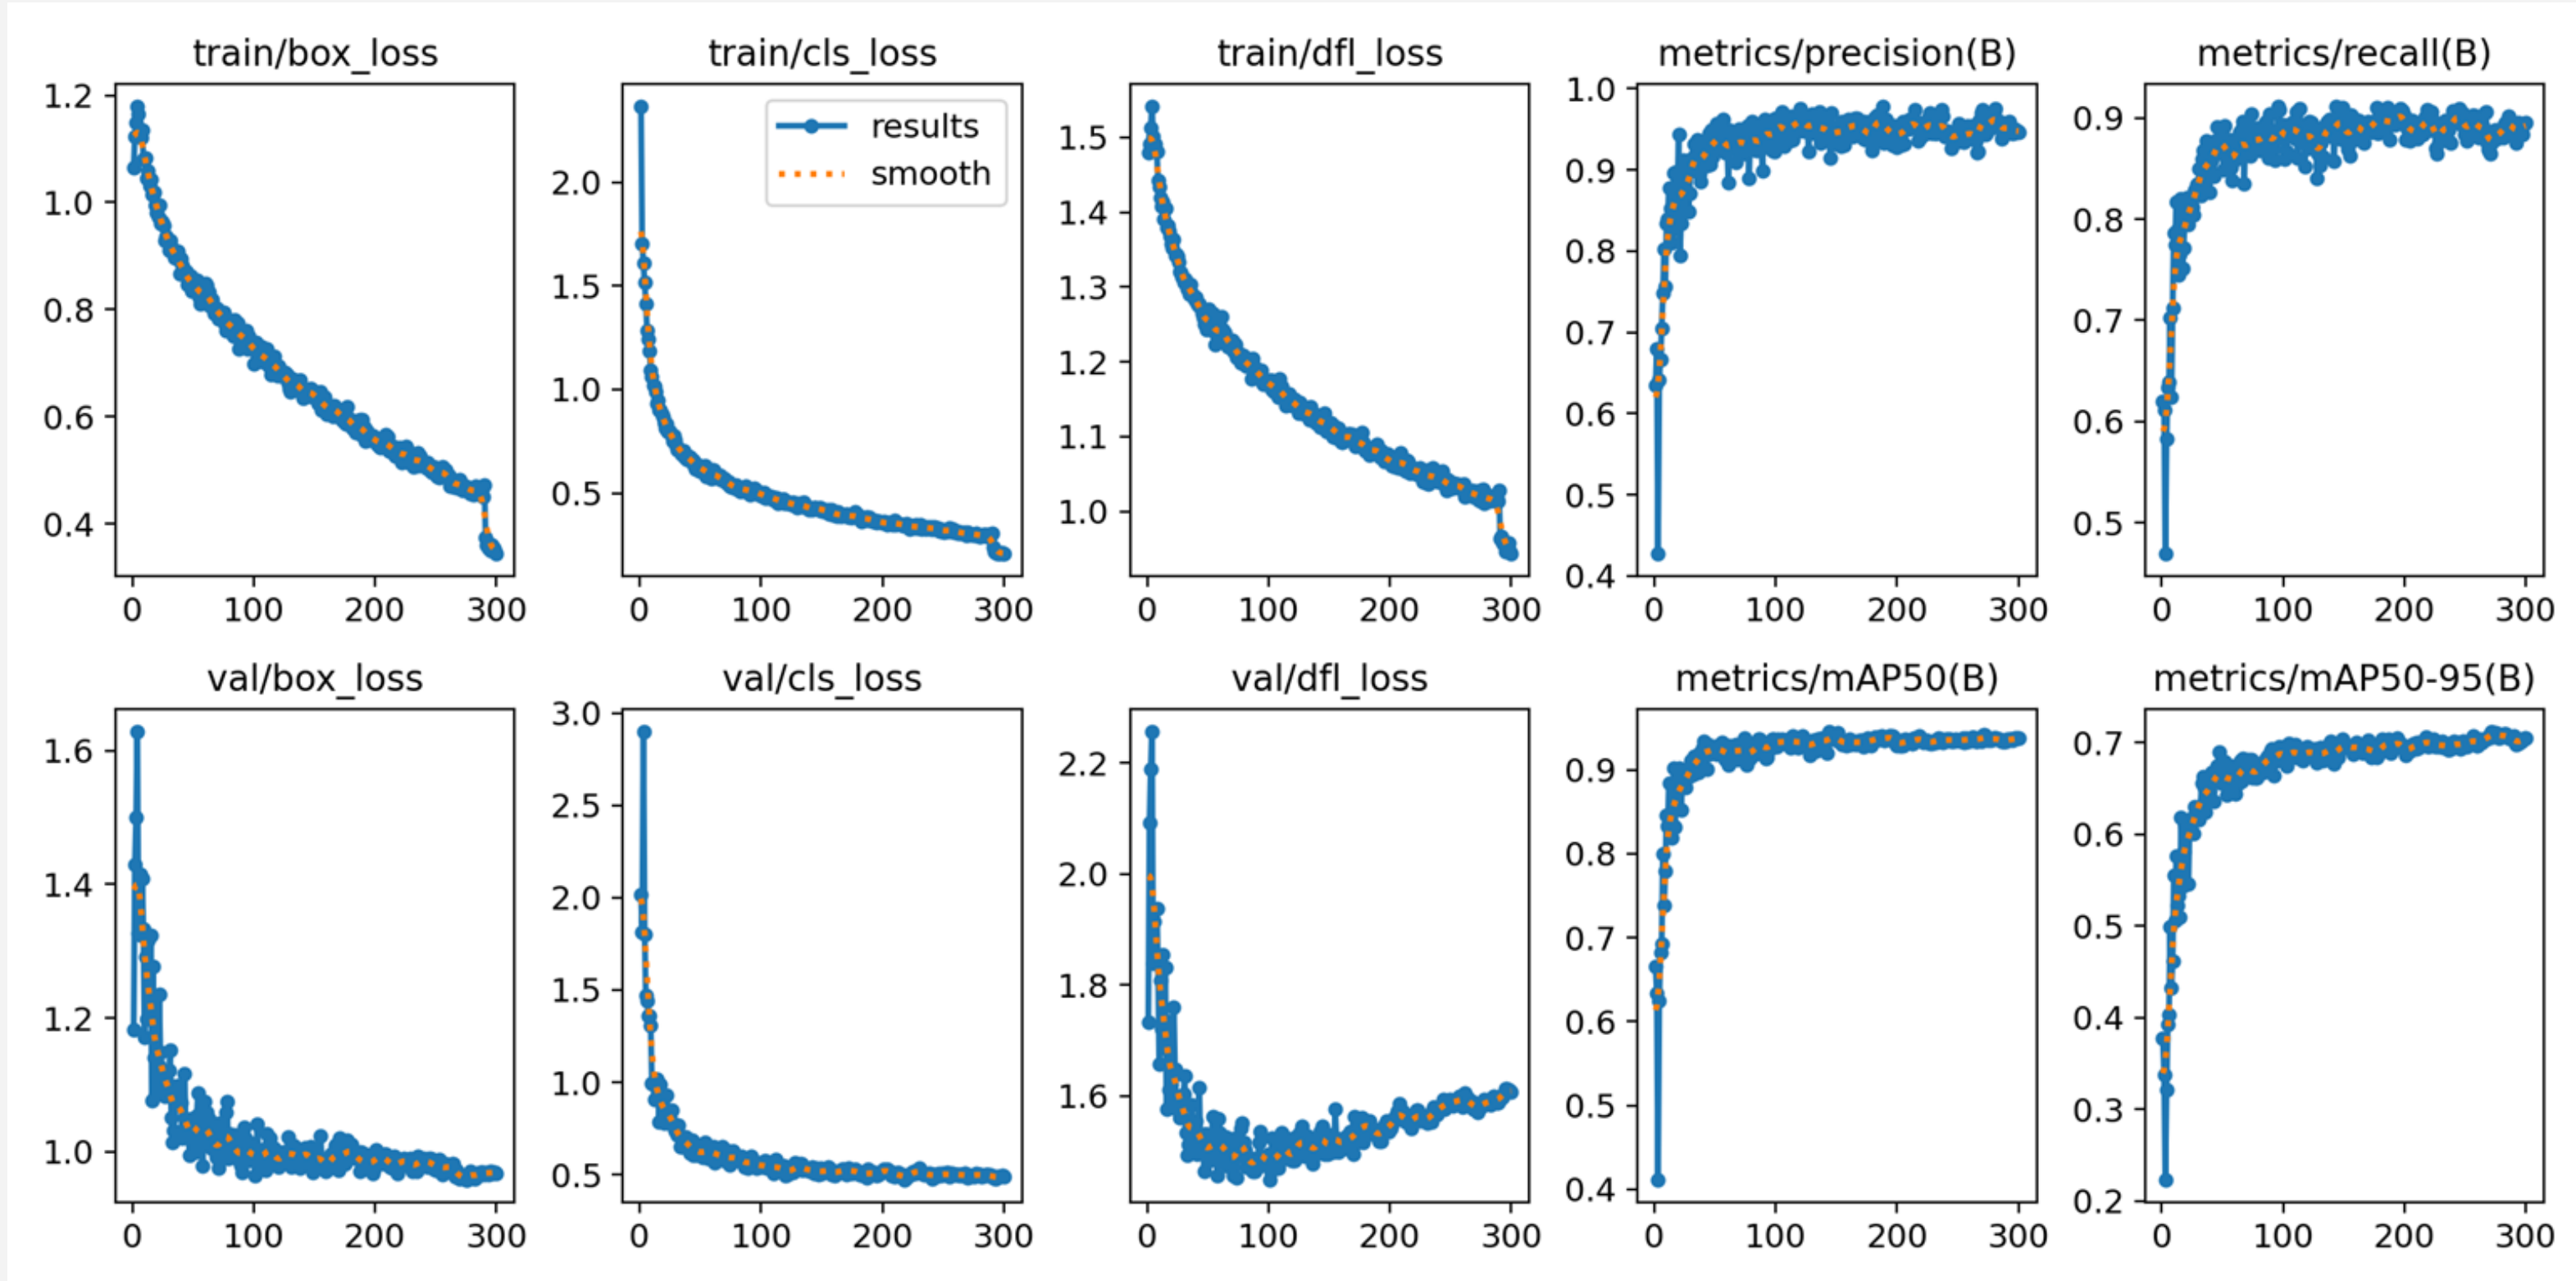
Resultados



Resultados




Resultados




Resultados

Float32 - best_float32.tflite							
FPS	CPU	RAM	mAP50	Precisão	Recall	F1-Score	Tamanho
1,5	25%	1,5 GB	94%	97%	88%	92%	12 MB
FLOAT16 - best_float16.tflite							
2,3	23%	1,2 GB	92%	93%	88%	90%	6 MB
INT8 - best_int8.tflite							
2,5	20%	1,1 GB	92%	94%	87%	90%	3 MB

Resultados



Medição: 1 m
Resultado: 0.91 m



Medição: 2 m
Resultado: 2.11 m



Medição: 5 m
Resultado: 4.95 m



Medição: 20 m
Resultado: 20.02 m



Medição: 20 m
Resultado: 20.08 m


Estes foram alguns **testes de distância** feitos, para validar se realmente estava conseguindo obter um valor mínimo confiável. Utilizamos uma trena de **30 metros** para mensurar e compara o valor real com o obtido em simulação. A margem de erro em módulo foi de **$\pm 0.11\text{m}$** .

Obs.: teste feito com 1 hora de gravação.

Resultados




Medição: 20 km/h
Resultado: 20 km/h



Medição: 10 km/h
Resultado: 10 km/h



Medição: 10 km/h
Resultado: 10 km/h



Medição: 30 km/h
Resultado: 19 km/h



Medição: 30 km/h
Resultado: 28 km/h



Medição: 30 km/h
Resultado: 32 km/h

Estes agora foram os testes de velocidade, solicitando aos motoristas que fiquem uma velocidade X constante. A margem de erro para este teste foi de aproximadamente ± 4 km/h.

obs.: Teste feito com 1 hora de gravação.

Resultados - Local - modelo padrão



Resultados - Local - modelo quantizado





Resultados - RaspBerry PI 4 Model B




Melhorias

- Otimizar o código, para alcançar maior desempenho sem perda de frame;
- Utilizar acelerador de Redes Neurais, sendo por software ou hardware, como PyArmnn, ou Google Edge TPU Coral.
- Utilizar a câmera na perspectiva lateral do carro evitando sobreposição do bounding boxes. E buscar uma área maior.
- Ao utilizar uma área maior, buscar mais pontos e averiguar outras métricas com a Matriz de Homografia.





Melhorias






- Aumentar a quantidade de dispositivos, sincronizar os dispositivos com algum servidor em cloud.
- Aumentar a resolução do modelo para torná-lo mais preciso, porem ainda mantendo o FPS mais alto.
- Utilizar mecanismos de criptografia em borda, e em transmissão, evitando entrada ou manipulação de dos dados e borramento dos rostos e placas dos carros.
- Utilizar algum algoritmo OCR que capture as placas dos carros e identifique-as, notificando além da velocidade, o nome da placa do veículo.

✦ Conclusão

A solução baseada em algoritmos de detecção de objetos YOLO e dispositivos de borda como o Raspberry Pi mostrou-se eficaz para gerenciar o tráfego.

Ofereceu dados precisos sobre o fluxo de veículos, velocidade e distância, melhorando a segurança, demonstrando uma margem de erro pequena em questão de velocidade e distância, com uma inferência em um tempo razoavelmente bom, suficiente para se poder processar o que é necessário.



Referências

- https://www.uio.no/studier/emner/matnat/its/TEK5030/v23/lectures/07-feature-matching/estimating-homographies-from-feature-correspondences_2023.pdf
- <https://auth.berkeley.edu/cas/login?service=https%3a%2f%2finst.eecs.berkeley.edu%2f%7eee290t%2ffa19%2flectures%2flecture8-homography.pdf>
- <https://learnopencv.com/homography-examples-using-opencv-python-c/>
- Jocher, G., Chaurasia, A., & Qiu, J. (2023). Ultralytics YOLO (Version 8.0.0) [Computer software]. <https://github.com/ultralytics/ultralytics>
- <https://universe.roboflow.com/dataset-ic/tipos-de-veiculos>
- <https://blog.roboflow.com/estimate-speed-computer-vision/>
- <https://auth.berkeley.edu/cas/login?service=https%3a%2f%2finst.eecs.berkeley.edu%2f%7eee290t%2ffa19%2flectures%2flecture8-homography.pdf>
- <https://blog.roboflow.com/video-stream-analysis/>
- <https://pessoal.dainf.ct.utfpr.edu.br/rminetto/projects/vehicle-speed/>
- <https://arxiv.org/pdf/2003.13137v2>
- <https://ieeexplore.ieee.org/abstract/document/7576700/>



Obrigado!


Perguntas?

hyago.silva@mtel.inatel.br

+55 35 9 9725 3305



<https://www.linkedin.com/in/hyagovieira/>



<https://github.com/HyAgOsK/>

